

Study on Underwater Sounds Classification with AI Models

Giuseppe D'avino^a, Daniele Dello Russo^{a,**}

^a*Faculty of Computer Science , Unisa – Università degli studi di Salerno, Via Giovanni Paolo II, 132, 84084 Fisciano, Italy*

Abstract

Le attività antropiche esercitano un impatto crescente sugli ecosistemi marini, modificando la biodiversità e minacciando la stabilità degli habitat. L'inquinamento acustico, generato da attività come la navigazione, l'estrazione di risorse naturali e il traffico marittimo, interferisce con le capacità di comunicazione e di orientamento di numerose specie, mettendone a rischio la sopravvivenza. Diventa quindi cruciale distinguere i segnali acustici naturali da quelli di origine antropica, per valutare l'entità del disturbo e definire strategie di mitigazione. In questo studio, sono stati sviluppati e valutati modelli d'Intelligenza Artificiale per la classificazione dei segnali audio marini, affrontando due compiti distinti: una classificazione binaria, per individuare i segnali audio di origine antropogenica da quelli che non lo sono, e una classificazione multiclasse, per identificare le sottocategorie dei segnali audio di origine antropogenica. Utilizzando diverse configurazioni di feature e due frequenze di campionamento (96 kHz e 44.1 kHz), i risultati hanno mostrato che il modello LightGBM ha fornito le migliori performance in entrambe le classificazioni. In particolare, la configurazione con frequenza di campionamento di 96 kHz ha raggiunto il miglior punteggio F1-score nella classificazione binaria, mentre per la classificazione multiclasse, la stessa frequenza di campionamento ha ottenuto il miglior compromesso tra accuratezza e capacità di generalizzazione. I risultati evidenziano l'importanza della scelta della frequenza di campionamento e delle feature nel migliorare la discriminazione dei segnali, offrendo un approccio promettente per il monitoraggio acustico degli habitat marini

Keywords:

Classificazione Multiclasse, Classificazione Binaria, Intelligenza Artificiale, Features Extraction, Signal Processing, LightGBM

1. INTRODUZIONE

Gli ecosistemi marini rivestono un ruolo essenziale nell'equilibrio ecologico globale, fornendo habitat a un'ampia pletora di specie e contribuendo significativamente alla regolazione del clima terracqueo. Tuttavia, l'intensificarsi delle attività di origine antropica sta provocando un rapido deterioramento di questi ambienti, minacciandone la biodiversità e le funzioni ecologiche. Il rumore subacqueo generato da attività antropiche, quali il traffico navale, le esplorazioni geosismiche per l'estrazione di risorse e le operazioni militari, ha raggiunto alti livelli di diffusione. Questo inquinamento acustico interferisce con funzioni biologiche fondamentali di molte specie marine, come la comunicazione, l'orientamento, la ricerca del cibo e la riproduzione. In particolare, i cetacei, che fanno affidamento sull'ecolocalizzazione, risultano essere particolarmente vulnerabili (Hildebrand, 2009)⁸. Inoltre, l'esposizione prolungata a livelli elevati di rumore può provocare alterazioni comportamentali e danni, aumentando il rischio di vulnerabilità per tali

specie (Blumstein et al., 2011)². Anche l'introduzione di sostanze chimiche di origine artificiale, inclusi fertilizzanti, pesticidi, metalli pesanti e idrocarburi, costituisce una minaccia rilevante. Queste sostanze contaminanti si accumulano lungo la catena trofica, generando effetti tossici che compromettono la salute della fauna marina (Erbe et al., 2017)²⁶. Questi fenomeni, sono spesso correlati al rilascio di prodotti agricoli, che hanno portato alla formazione di zone anossiche, causando la perdita di biodiversità su larga scala. Le attività di pesca intensiva hanno ulteriormente aggravato la situazione, alterando le gerarchie delle popolazioni marine e portando molte specie a un sovrasfruttamento critico. Pratiche come la pesca a strascico, danneggiano irreparabilmente il fondale marino, costituito dalle barriere coralline e le praterie sottomarine (Gibb et al., 2019)⁶. Contemporaneamente, i cambiamenti climatici, caratterizzati da un aumento delle temperature oceaniche e dall'acidificazione delle acque, stanno influenzando la distribuzione delle specie, la riproduzione e la disponibilità di risorse nutritive (Hildebrand, 2009)⁸. In questo contesto, il presente studio si propone di contribuire alla salvaguardia delle aree marine a rischio attraverso lo sviluppo di un sistema di classificazione di segnali audio avanzato, volto a distinguere tra suoni antropogenici "Target" e suoni di

*Corresponding author. Email: g.davino27@studenti.unisa.it

**Corresponding author. Email: d.dellorusso1@studenti.unisa.it

origine naturale "Non Target" tenendo in considerazione l'eventuale distorsione presente in tali segnali audio. Nella classificazione binaria, il focus principale è discriminare tra segnali audio che riflettono attività antropogeniche e segnali audio che non presentano tali caratteristiche. La classificazione multiclasse, invece, punta a identificare la specifica sotto-categoria di attività antropogenica a cui i segnali audio Target appartengono. Per raggiungere questi obiettivi, sono state applicati modelli per il riconoscimento e l'analisi dei segnali audio. In particolare, l'estrazione di features numeriche rilevanti dai segnali audio ha consentito di addestrare modelli di intelligenza artificiale, impiegati per eseguire le classificazioni con un'elevata precisione (Salamon et al., 2017)¹⁵. Questo approccio rappresenta un passo significativo verso la comprensione e la mitigazione degli impatti antropici sugli ecosistemi marini.

2. STATO DELL'ARTE

La letteratura scientifica prende in esame un vasto spettro di descrittori impiegati nella classificazione dei segnali bioacustici, derivanti da discipline quali la statistica, la teoria dell'informazione e l'elaborazione dei segnali. I parametri come il centroide spettrale, la larghezza di banda, la skewness, la curtosi e l'entropia di Shannon sono ampiamente utilizzati per discriminare le vocalizzazioni di diverse specie, incluse quelle marine. Allo stesso tempo, tecniche come l'analisi multistadio delle medie spettrali hanno dimostrato un'elevata flessibilità nel riconoscimento di richiami acustici prodotti da uccelli, anfibi e mammiferi marini (Giannakopoulos, 2014)⁷. L'integrazione di entropie di Shannon e Rényi, derivanti dalla teoria dell'informazione, ha inoltre evidenziato una notevole robustezza nella classificazione di segnali complessi, mentre l'estrazione di caratteristiche dagli spettrogrammi ha permesso l'applicazione di algoritmi di computer vision per l'individuazione e la localizzazione di eventi bioacustici (Blumstein et al., 2011; Sueur et al., 2008)²¹⁷. Con l'avvento del machine learning, la costruzione di modelli predittivi ha subito un miglioramento significativo. Algoritmi supervisionati come Random Forest (RF)²⁰, Support Vector Machine (SVM)²¹ e LightGBM²² si sono dimostrati particolarmente efficaci in molteplici scenari acustici grazie alla loro capacità di gestire dataset complessi e offrire prestazioni competitive. Un elemento cruciale nel processo di classificazione è la rappresentazione dei dati: le registrazioni acustiche, inizialmente rappresentate come samples discreti nel dominio del tempo, vengono trasformate in vettori di descrittori attraverso tecniche di estrazione delle caratteristiche. Questo processo, spesso combinato con metodi di riduzione della dimensionalità, migliora sia l'efficienza computazionale che la precisione dei modelli (Duda et al., 2001; Friedman, 2001)^{23 24}. Nel contesto della classificazione dei segnali acustici, l'estrazione di feature numeriche si è rivelata fondamentale

per migliorare le prestazioni predittive. Ad esempio, (Malfante et al.)¹¹ hanno ottenuto accuratèzze superiori all'85% nel riconoscimento dei segnali audio prodotti da specie ittiche in ambienti marini caratterizzati da forte rumore di fondo, sfruttando parametri statistici (ad esempio energia su bande di frequenza, rapporto segnale-rumore, zero-crossing rate) e spettrali (come ampiezza di picco, skewness e kurtosi), successivamente analizzati tramite SVM e RF. Altri studi, come quello di (Dhamodaran et al.)¹⁹, evidenziano che l'integrazione di coefficienti spettrali (MFCC) con parametri derivati dal dominio del tempo (zero-crossing rate) incrementano significativamente le metriche F1-score rispetto all'uso isolato di una singola categoria di feature. Parallelamente, (Kahl et al.)⁹, attraverso l'architettura (BirdNET)²⁵, ha dimostrato i vantaggi di approcci ibridi che combinano feature numeriche con rappresentazioni apprese da reti neurali profonde. In condizioni acustiche sfavorevoli, tali approcci hanno mostrato miglioramenti di oltre il 10% in accuratezza grazie all'utilizzo di descrittori tradizionali, come MFCC e roll-off spettrale, con l'integrazione di tecniche come il deep learning. In sintesi, questi studi sottolineano l'importanza strategica dell'estrazione e selezione di feature numeriche nella pipeline di classificazione dei segnali acustici. Questa fase di feature engineering, se combinata con metodologie di validazione, consente di bilanciare efficacemente la precisione predittiva e costi computazionali, rendendo tali approcci ideali per applicazioni pratiche e progetti di ricerca avanzati.

3. STRUTTURA DEL DATASET

Categoria	Lista dei dataset di provenienza
Non Target	-Watkins Marine Mammal Sound -A Collection of Sounds from the Sea -Sounds Recorded in Glacier Bay -SanctSound -Ocean Conservation Research -Avisoft -Sounds in the Ocean: Mammals -Marine Mammals Bioacoustic of Australia and Antarctica
Target	-A Collection of Sounds from the Sea -Sounds Recorded in Glacier Bay -SanctSound -Ocean Conservation Research -Deepship

Table 1: Tabella dei dataset utilizzati

Il Dataset utilizzato in questo studio è stato prodotto assemblando segnali audio provenienti da vari fonti come mostrato nella tabella 1 riassuntiva . Il dataset risultante fornisce un ampio spettro di segnali audio di origine bioacustica, ambientale e antropogenica oltre al rumore introdotto dal campionamento. Per fornire

una distinzione concreta dei segnali audio d'interesse per lo studio, il dataset è stato suddiviso in due macro categorie principali: "Non-Target" e "Target". La categoria "Target" è rappresentata da 663 segnali audio contenuti nello specifico diverse rappresentazioni di suoni ambientali e antropogenici. La categoria "Non-Target" include 2000 segnali audio che forniscono un insieme cospicuo di diverse specie marine e segnali audio di origine ambientali.

4. DATA PREPROCESSING

Il data preprocessing è stato finalizzato all'adattamento del dataset originale per garantire l'idoneità all'addestramento di diversi modelli di intelligenza artificiale, con particolare attenzione ai compiti di classificazione binaria e multiclasse. Durante questa fase, sono state applicate diverse operazioni per migliorare la qualità dei dati e semplificarne l'elaborazione. L'analisi del dataset ha evidenziato la presenza di 50 segnali audio duplicati nella classe Non-Target, successivamente rimossi per evitare distorsioni nei risultati, riducendo così il numero totale di segnali a 2613. Sono state inoltre condotte analisi per l'estrazione delle caratteristiche distintive dei dati, guidando le strategie di preprocessing adottate.

Un passaggio essenziale ha riguardato la normalizzazione dell'ampiezza dei segnali, scalata nell'intervallo tra -1 e 1 per uniformare i livelli di volume e migliorare la comparabilità tra le registrazioni. Questo processo ha evitato bias dovuti a variazioni di ampiezza, un fattore critico nel machine learning, dove differenze significative nei livelli di segnale possono compromettere la stabilità numerica dei modelli di classificazione (McFee et al., 2015)²⁷.

Per garantire l'omogeneità dei dati, tutti i segnali audio sono stati convertiti nel formato standard .wav con una profondità di 16 bit PCM. Questa scelta ha assicurato la compatibilità con le principali librerie di elaborazione audio, facilitando la standardizzazione necessaria per l'addestramento dei modelli AI. La conversione da stereo a monocolore ha ulteriormente ridotto la complessità computazionale, migliorando l'efficienza dell'elaborazione e del training.

Due valori di ricampionamento sono stati selezionati: 96.000 Hz e 44.100 Hz. Questa scelta ha soddisfatto i requisiti di Nyquist²⁸ sui sottoinsiemi di distribuzioni significativi, prevenendo l'aliasing e garantendo una rappresentazione accurata delle componenti frequenziali nei segnali. La classe Non-Target presentava frequenze tra 600 Hz e 384.000 Hz, mentre la classe Target variava tra 2.000 Hz e 200.000 Hz.

Infine, la segmentazione dei file audio ha uniformato la lunghezza dei campioni. La durata media dei segnali, pari a 3,53 secondi, è stata standardizzata a 4 secondi. Per quelli più brevi, è stato aggiunto silenzio alla fine senza alterarne il contenuto informativo, garantendo la coerenza

nei dati di input.

5. Estrazione delle Features

L'estrazione delle features dai segnali audio rappresenta un passo fondamentale nella costruzione di modelli di intelligenza artificiale per l'analisi bioacustica. Ogni feature numerica selezionata consente di descrivere specifiche proprietà del segnale, facilitando la distinzione tra segnali bioacustici e antropogenici, nonché la classificazione delle sorgenti sonore. In questo contesto, le features spettro-temporali forniscono informazioni dettagliate sul contenuto spettrale e sulla struttura temporale dei segnali, che sono fondamentali per una corretta identificazione e classificazione.

Studi recenti hanno dimostrato che l'ottimizzazione e la selezione mirata di caratteristiche acustiche, come i Mel-frequency cepstral coefficients (MFCC), i centroidi spettrali e la skewness, possono incrementare significativamente le prestazioni dei modelli di Machine Learning, specialmente in contesti bioacustici complessi (Malfante et al., 2018)¹¹. In linea con questi risultati, è stato scelto un sottoinsieme del set di caratteristiche proposto da Malfante come primo gruppo di features ³ per gli esperimenti successivi. Parallelamente, il secondo set di features è stato composto da caratteristiche tratte da BirdNET²⁵, tra cui MFCC, Zero Crossing Rate, Centroide Spettrale e Chroma. Questi parametri sono stati selezionati per la loro capacità di rappresentare efficacemente aspetti fondamentali dei segnali audio, dimostrando un'elevata efficacia nei processi di classificazione. Come terzo set, è stato preso in considerazione il gruppo di caratteristiche proposto da (Dhamodaran et al.)¹⁹, che amplia ulteriormente la gamma di feature considerate, includendo parametri derivati sia dal dominio temporale che da quello spettrale, con l'obiettivo di massimizzare le prestazioni dei modelli testati.

Features secondo Set con PCA	
	MFCC 1
	MFCC 3
	MFCC 4
	MFCC 8
	MFCC 9
	MFCC 10
	MFCC 11
	MFCC 12
	MFCC 13
	ZCR

Table 2: Features PCA

Feature Sets		
Primo Set ¹¹	Secondo Set ²⁵	Terzo Set ¹⁹
Spectral Centroid Mean	MFCC 1	MFCC 1
Spectral Bandwidth RMS	MFCC 2	MFCC 2
Standard Deviation	MFCC 3	MFCC 3
Skewness	MFCC 4	MFCC 4
Kurtosis	MFCC 5	MFCC 5
Shannon Entropy	MFCC 6	MFCC 6
Renyi Entropy	MFCC 7	MFCC 7
Rate of Attack	MFCC 8	MFCC 8
Rate of Decay	MFCC 9	MFCC 9
Threshold Crossings	MFCC 10	MFCC 10
Silence Ratio	MFCC 11	MFCC 11
Mean	MFCC 12	MFCC 12
Max Over Mean	MFCC 13	MFCC 13
Min Over Mean	ZCR	ZCR
Energy-Measurements	SpectralCentroid	SpectralContrast
-	SpectralBandwidth	Tonnetz 1
-	Chroma 1	Tonnetz 2
-	Chroma 2	Tonnetz 3
-	Chroma 3	Tonnetz 4
-	Chroma 4	Tonnetz 5
-	Chroma 5	Tonnetz 6
-	Chroma 6	Chroma 1
-	Chroma 7	Chroma 2
-	Chroma 8	Chroma 3
-	Chroma 9	Chroma 4
-	Chroma 10	Chroma 5
-	Chroma 11	Chroma 6
-	Chroma 12	Chroma 7
-	-	Chroma 8
-	-	Chroma 9
-	-	Chroma 10
-	-	Chroma 11
-	-	Chroma 12
-	-	Time

Table 3: Tabella rappresentativa dei set di feature analizzati.

6. Split e Oversampling

Il dataset è stato preparato per la suddivisione e il bilanciamento, necessari per l'addestramento dei modelli di classificazione binaria e multiclasse. La distribuzione iniziale delle classi, prima dello split, è riportata nella Tabella 4.

Classe	Num. Samples
Target	43.181
Non-Target	7.812

Table 4: Distribuzione dei samples pre-Split.

Per la classificazione binaria, il dataset è stato ridimensionato a 49.429 samples, mentre per la classificazione multiclasse è stato ottenuto un dataset di 43.089 samples. Successivamente, il dataset è stato suddiviso in tre set distinti utilizzando una metodologia di split 80-10-10, per entrambe le configurazioni di classificazione. Per la classificazione binaria e multiclasse, la distribuzione dei campioni è riportata nelle tabelle 5 e 6.

La suddivisione è stata realizzata preservando la coesione dei segmenti appartenenti allo stesso "Parent",

Set	Num. Samples	%
Train	38789	78,47%
Val	5016	10,15%
Test	5624	11,38%

Table 5: Distribuzione dei samples Classificazione Binaria.

Set	Num. Samples	%
Train	33872	78,61%
Val	4403	10,22%
Test	4814	11,17%

Table 6: Distribuzione dei samples Classificazione Multiclasse.

per evitare contaminazioni tra i set, e garantendo che la distribuzione delle classi fosse rappresentativa in ciascun set, rispettando la proporzione dei dati originali per ciascuna categoria o sottoclasse, ove possibile. Per bilanciare le classi nel dataset, è stato utilizzato lo SMOTE (Synthetic Minority Oversampling Technique). Nella classificazione binaria, SMOTE è stato applicato al set di addestramento, aumentando la classe minoritaria Non-Target, portando il totale dei campioni di addestramento a 67.744 samples, con una distribuzione bilanciata tra le due classi principali. Per la classificazione multiclasse, SMOTE è stato applicato esclusivamente alla classe Target, aumentando la rappresentazione delle sottoclassi minoritarie fino a ottenere una distribuzione proporzionale rispetto alla sottoclasse maggioritaria. La classe Non-Target non è stata inclusa nel processo di bilanciamento per evitare distorsioni, ottenendo un set di addestramento finale di 44.150 samples, con una distribuzione equilibrata tra le sottoclassi della classe Target. Questa strategia ha permesso di ottimizzare il modello, concentrandosi sulle sottoclassi più rilevanti della classe Target, mantenendo al contempo un bilanciamento adeguato e senza influenze distorsive derivanti dalla classe Non-Target.

7. Addestramento

Gli addestramenti proposti sono stati eseguiti con due diverse workstation: un HP VICTUS con chip I5 12450H dotato di scheda grafica NVIDIA® GeForce RTX™ 4050 e un DELL dotato di chip I7 1360P e scheda grafica NVIDIA® GeForce RTX™ A500.

Le sperimentazioni sono state effettuate utilizzando tre modelli di classificazione distinti: Random Forest, Support Vector Machine (SVM) e LightGBM. Per ciascun modello, sono state valutate le capacità predittive applicando i set di feature estratti, descritti approfonditamente nella Sezione 5. La valutazione delle prestazioni dei modelli si è basata sull'F1-score pesato, calcolato come media ponderata sulle classi. Questa metrica è stata scelta in quanto rappresentativa della capacità complessiva

dei modelli di bilanciare precision e recall, risultando particolarmente adatta a contesti con distribuzioni di classe sbilanciate o in cui è fondamentale minimizzare sia i falsi positivi sia i falsi negativi. Particolare attenzione è stata dedicata alla differenza tra l’F1-score calcolato sui set di validazione e di test, per valutare la generalizzabilità dei modelli. I risultati degli esperimenti sono riportati in forma percentuale all’interno delle tabelle 7 8, con una precisione di quattro cifre significative, garantendo una rappresentazione accurata e dettagliata delle performance di ciascun modello. Questo livello di granularità consente di effettuare un confronto rigoroso tra le diverse configurazioni sperimentali e i set di features utilizzati.

7.1. Esperimenti Classificazione Binaria

Gli esperimenti hanno evidenziato una coerenza nel comportamento dei modelli testati rispetto alla frequenza di campionamento e ai set di feature utilizzati. Con una frequenza di 96.000 Hz, i risultati mostrano prestazioni significativamente elevate per tutti i modelli, con LightGBM che si distingue come il migliore. In particolare, il Set di Features 2 7 ha raggiunto un F1-score del 99,95% sul set di test, superando le altre configurazioni. Questo risultato suggerisce che il Set di Features 2 fornisce una rappresentazione particolarmente robusta, consentendo al modello di mantenere un’elevata capacità di generalizzazione anche su dati non precedentemente osservati. Quando i samples sono stati ricampionati a una frequenza di 44.100 Hz, è stata osservata una lieve riduzione delle performance complessive, sebbene LightGBM abbia continuato a ottenere migliori prestazioni. Anche in questa configurazione, il Set di Features 2 si è dimostrato ottimale, raggiungendo un F1-score del 99,86% sul set di test. L’applicazione della PCA (Principal Component Analysis), eseguita esclusivamente per questa frequenza, ha prodotto risultati leggermente inferiori rispetto al set di feature originale 2. Questo risultato indica che, sebbene la riduzione della dimensionalità renda l’estrazione più “leggera”, può introdurre una perdita di informazioni per una classificazione accurata. Le discrepanze tra i risultati sui set di validazione e di test sono risultate generalmente contenute, con leggere differenze negative sia per la frequenza di 96.000 Hz sia per quella di 44.100 Hz. Questi dati indicano che il modello LightGBM generalizza bene, mostrando una sensibilità minima alle variazioni dei dati di input. Tuttavia, le prestazioni superiori osservate con la frequenza di 96.000 Hz suggeriscono che una risoluzione maggiore nei sample migliora la capacità di discriminare le caratteristiche rilevanti per la classificazione binaria. In sintesi, la combinazione del modello LightGBM con il Set di Features 2 alla frequenza di 96.000 Hz rappresenta la configurazione ottimale per questo studio. Come si può desumere dalla confusion matrix 1 che conferma l’efficacia nel contesto della classificazione binaria.

7.2. Esperimenti Classificazione Multiclasse

L’analisi complessiva dei risultati della classificazione multiclasse evidenzia come l’accuratezza e la capacità predittiva, misurate tramite l’F1-score, siano fortemente influenzate sia dal set di feature adottato sia dalla frequenza di campionamento (44,1 kHz e 96 kHz). Sebbene la frequenza di 96 kHz teoricamente consenta di catturare un maggior livello di dettaglio nei segnali audio, i risultati sperimentali mostrano che i modelli non sempre riescano a trarne beneficio. Questo fenomeno può essere attribuito a problemi di overfitting e alla natura specifica del dataset. Al contrario, la frequenza di 44,1 kHz ha spesso prodotto risultati più stabili, permettendo inoltre l’applicazione della PCA 2, che ha migliorato la generalizzazione del modello senza compromettere significativamente la sua efficacia. Nel confronto tra i modelli Random Forest, SVM e LightGBM, quest’ultimo ha mostrato prestazioni complessivamente superiori nella maggior parte delle configurazioni. In particolare, la combinazione “Set Features 2 custom” 8 a 96 kHz è risultata la più performante in termini di bilanciamento tra prestazioni e generalizzazione, con un F1-score di 0,8457% sul set di validazione e 0,5207% sul set di test. Tuttavia, la discrepanza significativa tra i risultati di validazione e test suggerisce che probabilmente il modello ha appreso in modo specifico le caratteristiche del set di validazione, ma fatica a generalizzare sui dati mai visti. Contemporaneamente, la configurazione “Set Features 2 post PCA” 8 a 44.1 kHz ha ottenuto un F1-Score di 0,5600% in validazione e 0,5257% in test, mostrando una discrepanza minore tra i due set. Questa maggiore stabilità indica una migliore capacità di generalizzazione rispetto ad altre configurazioni. Un aspetto chiave emerso dall’analisi è la significativa discrepanza tra i risultati di validazione e test in diverse configurazioni, evidenziando potenziali problemi di overfitting e variazioni nella distribuzione dei dati. Ad esempio, la configurazione “Set Features 2 custom” ha raggiunto il valore più elevato in validazione, ma ha subito un drastico calo in test, suggerendo che il modello è stato ottimizzato in modo eccessivo per il set di validazione. Anche l’implementazione della strategia K-Fold, teoricamente utile per ridurre l’overfitting, non ha prodotto miglioramenti sostanziali, con un F1-Score sul set di test pari a 0,4767%. In definitiva, considerando sia le performance assolute sul set di test sia la stabilità tra validazione e test, la configurazione “Set Features 2 post PCA” a 44.1 kHz emerge come la più promettente per la classificazione multiclasse. Questo modello offre un buon compromesso tra accuratezza e capacità di generalizzazione. Tuttavia, le discrepanze osservate sottolineano la necessità di ulteriori strategie di ottimizzazione, come l’adozione di feature più robuste, tecniche di regolarizzazione e un migliore bilanciamento dei dati. Tali interventi potrebbero ridurre il rischio di overfitting e migliorare l’affidabilità predittiva del modello su dati reali.




Figure 1: Confusion Metrix Binaria di LightGBM con secondo Set di features




Figure 2: Confusion Metrix Multiclasse di LightGBM con terzo Set di features

Set	Sample Rate	Random Forest	SVM	LightGBM	Support
		Wavg F1-score(%)	Wavg F1-score(%)	Wavg F1-score(%)	
SET Features 1					
Val	44100Hz	—	—	—	—
Test	44100Hz	—	—	—	—
Val	96000Hz	0.9918	0.9003	0.9927	5016
Test	96000Hz	0.9844	0.9186	0.9905	5624
SET Features 2					
Val	44100Hz	—	—	0.9958	5016
Test	44100Hz	—	—	0.9929	5624
Val	96000Hz	0.9881	0.9800	0.9941	5016
Test	96000Hz	0.9900	0.9592	0.9956	5624
SET Features 2 post PCA					
Val	44100Hz	—	—	0.9927	5016
Test	44100Hz	—	—	0.9975	5624
Val	96000Hz	—	—	—	—
Test	96000Hz	—	—	—	—
SET Features 3					
Val	44100Hz	—	—	—	—
Test	44100Hz	—	—	—	—
Val	96000Hz	0.9852	0.9865	0.9915	5016
Test	96000Hz	0.9893	0.9861	0.9963	5624

Table 7: Tabella Esperimenti classificazione Binaria

Set	Sample Rate	Random Forest	SVM	LightGBM	Support
		Wavg F1-score(%)	Wavg F1-score(%)	Wavg F1-score(%)	
SET Features 1					
Val	44100Hz	—	—	—	—
Test	44100Hz	—	—	—	—
Val	96000Hz	0.3912	0.1840	0.4025	4403
Test	96000Hz	0.4163	0.1885	0.4094	4814
SET Features 2					
Val	44100Hz	—	—	0.5627	4403
Test	44100Hz	—	—	0.4945	4814
Val	96000Hz	0.4811	0.3367	0.5471	4403
Test	96000Hz	0.4412	0.3497	0.4890	4814
SET Features 2 custom					
Val	44100Hz	—	—	0.7623	4403
Test	44100Hz	—	—	0.5087	4814
Val	96000Hz	—	—	0.8454	4403
Test	96000Hz	—	—	0.5207	4814
SET Features 2 con K-fold					
Val	44100Hz	—	—	—	—
Test	44100Hz	—	—	0.4922	4814
Val	96000Hz	—	—	—	—
Test	96000Hz	—	—	0.4769	4814
SET Features 2 post PCA					
Val	44100Hz	—	—	0.5600	4403
Test	44100Hz	—	—	0.5257	4814
Val	96000Hz	—	—	—	—
Test	96000Hz	—	—	—	—
SET Features 3					
Val	44100Hz	—	—	—	—
Test	44100Hz	—	—	—	—
Val	96000Hz	0.4827	0.5198	0.5470	4403
Test	96000Hz	0.4381	0.4796	0.5079	4814

Table 8: Tabella Esperimenti classificazione Multiclasse

8. Conclusioni

Riassumendo, le sperimentazioni condotte, sia per la classificazione binaria sia per quella multiclasse, hanno evidenziato l'importanza critica della frequenza di campionamento e della selezione del set di feature nel determinare le prestazioni finali. Nel contesto binario, l'utilizzo di una frequenza di 96 kHz si è dimostrato particolarmente efficace, soprattutto in combinazione con il Set di Features 2 e il modello LightGBM, raggiungendo un F1-score del 99,95% sul set di test. Questa configurazione risulta ottimale poiché offre una rappresentazione estremamente ricca del segnale, preservando dettagli essenziali per distinguere accuratamente tra le due classi. Il ricampionamento a 44,1 kHz ha comportato una lieve riduzione delle performance, con un F1-score del 99,86%, ma LightGBM ha mantenuto le sue prestazioni ottimali grazie alla capacità di bilanciare efficacemente falsi positivi e falsi negativi, oltre alla sua ottima generalizzazione. Per la classificazione multiclasse, la frequenza di 44,1 kHz si è dimostrata più vantaggiosa nel bilanciare la complessità del modello e la stabilità dei risultati, consentendo anche l'applicazione della PCA modo efficace. In questo contesto, LightGBM si è confermato come il classificatore più performante. Il "Set di Features 2 post PCA", a 44,1 kHz, ha registrato i migliori F1-Score sul set di test, unendo una buona accuratezza a una discrepanza contenuta tra i risultati di validazione e test. Al contrario, la configurazione LightGBM con parametri più complessi ha mostrato una notevole divergenza tra l'elevata accuratezza in validazione (oltre l'84%) e quella in test (poco sopra il 52%), suggerendo la presenza di overfitting o differenze nella distribuzione dei dati tra i due subset. In sintesi, per la classificazione binaria, la combinazione di LightGBM e il "Set di Features 2" a 96 kHz si conferma come la configurazione più performante, offrendo equilibrio tra precisione, generalizzazione e gestione di falsi positivi e falsi negativi. Per la classificazione multiclasse, invece, la frequenza di 44,1 kHz associata al "Set di Features 2 post PCA" rappresenta la scelta ottimale, riducendo l'overfitting e garantendo una maggiore stabilità delle prestazioni su dati non

osservati. Questi risultati sottolineano la necessità di valutare attentamente la frequenza di campionamento e la selezione delle feature in relazione alla natura specifica del problema, ottimizzando il compromesso tra prestazioni, generalizzazione e complessità del modello.

9. Sviluppi Futuri

Gli sviluppi futuri di questo progetto potrebbero concentrarsi su diversi aspetti chiave per migliorare l'accuratezza e l'efficacia del modello di classificazione. In primo luogo, sarebbe opportuno utilizzare un dataset più ampio e diversificato, che includa una maggiore varietà di suoni bioacustici e antropogenici, raccolti in diverse condizioni ambientali. Un dataset più rappresentativo potrebbe migliorare la capacità del modello di generalizzare e adattarsi a una più ampia gamma di scenari reali. Inoltre, l'integrazione di combinazioni avanzate di caratteristiche numeriche (features) acustiche potrebbe permettere una rappresentazione più dettagliata dei segnali audio, consentendo di catturare meglio le peculiarità dei suoni bioacustici e antropogenici. L'uso di tecniche di feature selection e extraction, come l'analisi delle componenti principali (PCA) è risultata la chiave per migliorare diversi aspetti della classificazione, pertanto si dovrebbe continuare con la cross validation di altre features numeriche con ulteriori sperimentazioni. Inoltre altri metodi basati su deep learning, potrebbero ottimizzare la rappresentazione dei segnali, migliorando l'accuratezza del modello. Infine, l'impiego di modelli di Machine Learning più avanzati e complessi, come reti neurali convoluzionali (CNN) o modelli basati su apprendimento profondo, potrebbe incrementare le prestazioni del sistema. Un approccio ensemble, che combini diversi algoritmi di classificazione, potrebbe ulteriormente raffinare i risultati, sfruttando la complementarità tra i vari modelli per ottenere una maggiore robustezza nella distinzione tra suoni antropogenici e bioacustici. Questi sviluppi futuri offriranno un potenziale significativo per migliorare la capacità del sistema di supportare la gestione sostenibile degli ecosistemi marini attraverso una più accurata identificazione dei segnali acustici.

10. Bibliography

References

- [1] Bishop, C. M. (2006). *Pattern Recognition and Machine Learning*. Springer.
- [2] Blumstein, D. T., Mennill, D. J., Clemens, P., Girod, L., Yao, K., Patricelli, G., ... & Kirschel, A. N. (2011). Acoustic monitoring in terrestrial environments using microphone arrays: applications, technological considerations and prospectus. *Journal of Applied Ecology*, 48(3), 758-767.
- [3] Chawla, N. V., Bowyer, K. W., Hall, L. O., & Kegelmeyer, W. P. (2002). SMOTE: Synthetic Minority Over-sampling Technique. *Journal of Artificial Intelligence Research*, 16, 321-357.
- [4] Cover, T. M., & Thomas, J. A. (2006). *Elements of Information Theory*. John Wiley & Sons.
- [5] Figueroa, L., Belloni, M., & Abascal-Mena, R. (2015). Statistical modeling of cetacean click properties for automatic classification. *Journal of the Acoustical Society of America*, 137(3), 1025-1034.
- [6] Gibb, R., Browning, E., Glover-Kapfer, P., & Jones, K. E. (2019). Emerging opportunities and challenges for passive acoustics in ecological assessment and monitoring. *Methods in Ecology and Evolution*, 10(2), 169-185.
- [7] Giannakopoulos, T., & Pikrakis, A. (2014). *Introduction to Audio Analysis: A MATLAB® Approach*. Academic Press.
- [8] Hildebrand, J. A. (2009). Anthropogenic and natural sources of ambient noise in the ocean. *Marine Ecology Progress Series*, 395, 5-20.
- [9] Kahl, S., Wood, C. M., Eibl, M., & Klinck, H. (2021). BirdNET: A deep learning solution for avian diversity monitoring. *Ecological Informatics*, 61, 101236.
- [10] Lerch, A. (2012). *An Introduction to Audio Content Analysis: Applications in Signal Processing and Music Informatics*. John Wiley & Sons.
- [11] Malfante, M., Mars, J. I., Dalla Mura, M., & Gervaise, C. (2018). Automatic fish sounds classification in real-life marine environments: Performance evaluation and perspectives. *Journal of the Acoustical Society of America*, 143(5), 2834-2845.
- [12] Mellinger, D. K., & Clark, C. W. (2000). Recognizing transient low-frequency whale sounds by spectrogram correlation. *The Journal of the Acoustical Society of America*, 107(6), 3518-3529.
- [13] Mermelstein, P. (1976). Distance measures for speech recognition, psychological and instrumental. *Pattern Recognition and Artificial Intelligence*, 116, 374-388.
- [14] Popescu, M., Ehrlich, R., & Xu, W. (2009). Detection and classification of acoustic events for in-home monitoring of an elder person living alone. In *Proceedings of the 6th IEEE International Conference on Advanced Video and Signal Based Surveillance (AVSS)* (pp. 314-319).
- [15] Salamon, J., Bello, J. P., Farnsworth, A., & Rosenheim, K. (2017). Feature learning with convolutional neural networks for bioacoustics. In *2017 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)* (pp. 2662-2666). IEEE.
- [16] Sharma, R., Agarwal, S., & Jain, R. (2020). Acoustic signal classification using hybrid features and machine learning techniques. *Journal of Ambient Intelligence and Humanized Computing*, 11(3), 1171-1180.
- [17] Sueur, J., Aubin, T., & Simonis, C. (2008). Equipment review: Seewave, a free modular tool for sound analysis and synthesis. *Bioacoustics*, 18(2), 213-226.
- [18] Tzanetakis, G., & Cook, P. (2002). Musical genre classification of audio signals. *IEEE Transactions on Speech and Audio Processing*, 10(5), 293-302.
- [19] Dhamodaran, P., Balakrishnan, V., & Dharmavaram, A. (2023). A Survey on Audio Feature Extraction for Automatic Music Genre Classification. *International Journal of Recent Technology and Engineering*, 12(3), 45-52.
- [20] Breiman, Leo. "Random forests." *Machine learning* 45 (2001): 5-32.
- [21] Boser, B.E., Guyon, I.M. and Vapnik, V.N. (1992) A Training Algorithm for Optimal Margin Classifiers. *Proceedings of the Fifth Annual Workshop on Computational Learning Theory*, Pittsburgh, July 1992, 144-152
- [22] Ke, G. et al., 2017. Lightgbm: A highly efficient gradient boosting decision tree. *Advances in neural information processing systems*, 30, pp.3146-3154
- [23] R. O. Duda, P. E. Hart and D. G. Stork, "Pattern Classification," 2nd Edition, John Wiley and Sons, Inc., New York, 2001.
- [24] Friedman, J.H. (2001) Greedy Function Approximation: A Gradient Boosting Machine. *Institute of Mathematical Statistics*, 29, 1189-1232
- [25] Kahl, S., Wood, C. M., Eibl, M., Klinck, H. (2021). BirdNET: A deep learning solution for avian diversity monitoring. *Ecological Informatics*, 61, 101236
- [26] Erbe, C., Dunlop, R., Jenner, K. C. S., Jenner, M.-N. M., McCauley, R. D., Parnum, I., Parsons, M., Rogers, T., and Salgado-Kent, C. (2017). Review of underwater and in-air sounds emitted by Australian and Antarctic marine mammals. *Acoustics Australia*, 45, 179-24
- [27] McFee, B., Raffel, C., Liang, D., Ellis, D. P. W., McVicar, M., Battenberg, E., Nieto, O. (2015). LibROSA: Audio and music signal analysis in Python. *Proceedings of the 14th Python in Science Conference*, 18-25
- [28] Nyquist, H. (1928). "Certain topics in telegraph transmission theory." *Transactions of the American Institute of Electrical Engineers*, 47(2), 617-644